

Detecção automática de bordas em imagens através do uso de operadores diferenciais

Alexandre Regali Seleghim

Alexandre Luis Magalhães Levada

Resumo: Na área de processamento de imagens é muito importante o problema da detecção automática de bordas em imagens. Uma das estratégias mais tradicionais para resolver este problema é a abordagem matemática. Ela consiste em utilizar operadores diferenciais que agem como filtros na imagem, produzindo o resultado de destacar as linhas e contornos detectados na imagem.

Este trabalho visa conhecer os principais operadores diferenciais utilizados na detecção de bordas em imagens, bem como suas diferenças entre si e seus resultados.

Palavras-chave: detecção de bordas, operadores diferenciais, filtros, processamento de imagens.

1 INTRODUÇÃO

Detectar as linhas e contornos dentro de uma imagem é um problema de grande importância dentro da área de processamento de imagens. A solução deste problema pode ser um fim em si mesmo (a simples detecção de linhas e contornos), ou pode servir como uma etapa de pré-processamento na resolução de problemas maiores (com o objetivo de reduzir a dimensionalidade do problema, eliminar poluição ou informação desnecessária, identificar objetos, etc).

Uma das estratégias mais adotadas para resolver este problema é a abordagem matemática. Ela consiste em trabalhar com a imagem em sua forma matricial, aplicando nela operadores diferenciais que convolucionam todas as regiões da matriz produzindo o resultado visual de destacar as linhas e contornos dentro da imagem.

Existem diversos operadores diferenciais conhecidos para a detecção automática de bordas em imagens. Neste trabalho, nos atentaremos à quatro: Sobel, Prewitt, Roberts e Laplacian of Gaussian. Estes são os mais populares e mais implementados em diversas bibliotecas

gráficas usuais. Também contaremos com uma implementação do detector de Canny. Ele será importante pois é o estado da arte da detecção de bordas em imagens e então servirá de gabarito tanto em nossas análises quantitativas quanto qualitativas dos resultados.

Será realizado uma implementação de um algoritmo de convolução, bem como também os operadores diferenciais citados para serem utilizados na convolução. Usaremos convoluções com base em um único operador e também com base em mais de um operador. Para múltiplos operadores, o resultado final da convolução será uma média quadrática dos resultados dos operadores. A implementação será feita em Javascript e o resultado será exposto em uma aplicação web usando HTML + CSS. Esta combinação permite que o resultado do trabalho possa ser acessado através de qualquer dispositivo com um navegador e acesso à internet. O código fonte também será disponibilizado de forma open-source em um repositório no Github.

2 TRABALHOS RELACIONADOS

Uma revisão sistemática foi realizada para identificar quais são os principais operadores diferenciais, como eles foram estudados e qual a melhor metodologia de análise de resultados. Os operadores escolhidos para este trabalho (Sobel, Prewitt, Roberts e Laplacian of Gaussian) foram os principais abordados em outros trabalhos. O artigo *On edge detection* (TORRE; POGGIO, 1986) mostrou que estes operadores podem ser sutilmente modificados para obtermos diferentes resultados, sem ferir o propósito principal que é detectar bordas. Isto é importante para entendermos que não existem uma forma canônica desses operadores, mas sim diferentes versões deles.

Ao buscar qual a melhor forma de se anali-

sarmos os resultados dos operadores, a maioria dos trabalhos apresentaram avaliações qualitativas. No trabalho *A study on edge marking scheme of various standard edge detectors* (PANDE; BHADOURIA; GHOSHAL, 2012), encontramos um método para realizar uma avaliação quantitativa dos resultados através do *Pratt's figure of merit* (PFOM). Ele consiste em calcular as diferenças entre o resultado obtido e um gabarito (*gold standard*). A métrica resultante é um número variando de 0 a 1 que indica a porcentagem de similaridade entre o resultado obtido e o resultado ideal. Por se tratar de uma implementação complexa, neste presente trabalho adotamos uma versão simplificada do PFOM, mas que também trouxe uma métrica resultante similar.

3 DESENVOLVIMENTO

A primeira etapa do processo é transformar nossa imagem em uma escala de cinza. As informações sobre as cores (por exemplo valores RGB) são informações desnecessárias para o nosso algoritmo de convolução. A imagem, originalmente sendo uma matriz onde cada célula conteria as informações da tripla RGB, passa a possuir apenas um valor variando de 0 a 255 (onde 0 é o preto total e 255 é o branco total). Para isso, o novo valor que representará nossa escala de cinza será obtido a partir da seguinte formula:

$$Cinza = 0.2126R + 0.7152G + 0.0722B$$

É comum nesta etapa aplicar à imagem um filtro que "borre" a imagem, para que pequenas perturbações na imagem desapareçam ao serem borrados. Isso faz com que essas perturbações não sejam identificadas como bordas, tendo assim como resultado apenas as bordas mais expressivas na imagem. Utilizamos o operador de borra conhecido como Gaussian Blur:

$$\frac{1}{273} \begin{bmatrix} +1 & +4 & +7 & +4 & +1 \\ +4 & +16 & +26 & +16 & +4 \\ +7 & +26 & +41 & +26 & +7 \\ +4 & +16 & +26 & +16 & +4 \\ +1 & 4 & +7 & +4 & +1 \end{bmatrix}$$

Realizado esta conversão, passamos então a aplicar nossos operadores diferenciais. Simplificando, eles funcionam como uma máscara que calculam pixel por pixel em nossa imagem se há uma brusca variação na escala de cinza em relação aos pixels adjacentes. Na Figura 1 podemos intuitivamente reconhecer que há uma alta variação entre o quarto e quinto pixel.

É justamente essa brusca variação que denuncia uma borda em nossa imagem. Essa variação pode ocorrer em pixels adjacentes horizontais ou verticais. Nossos operadores diferenciais calculam a intensidade de cada borda analisando as derivadas locais da nossa vizinhança de pixels e procurando por repentinas variações na magnitude da escala de cinza.

Os operadores são aplicados em nossa imagem através de um algoritmo de convolução. Ele consiste em calcular uma média ponderada de toda uma vizinhança de pixels, e atribuindo ao pixel central o valor do resultado. Esse processo é realizado em toda a imagem, um pixel de cada vez, como descrito na Figura 2.

Na Figura 2, temos em K o nosso kernel (operador diferencial) utilizado. Esse kernel é o nosso conjunto de pesos a ser utilizado no cálculo de nossa média ponderada na etapa de convolução. Temos, por exemplo, os seguintes kernels:

3.1 SOBEL

$$Gx = \begin{bmatrix} +1 & 0 & -1 \\ +2 & 0 & -2 \\ +1 & 0 & -1 \end{bmatrix}$$


$$Gy = \begin{bmatrix} +1 & +2 & +1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix}$$

3.2 PREWITT

$$Gx = \begin{bmatrix} -1 & 0 & +1 \\ -1 & 0 & +1 \\ -1 & 0 & +1 \end{bmatrix}$$

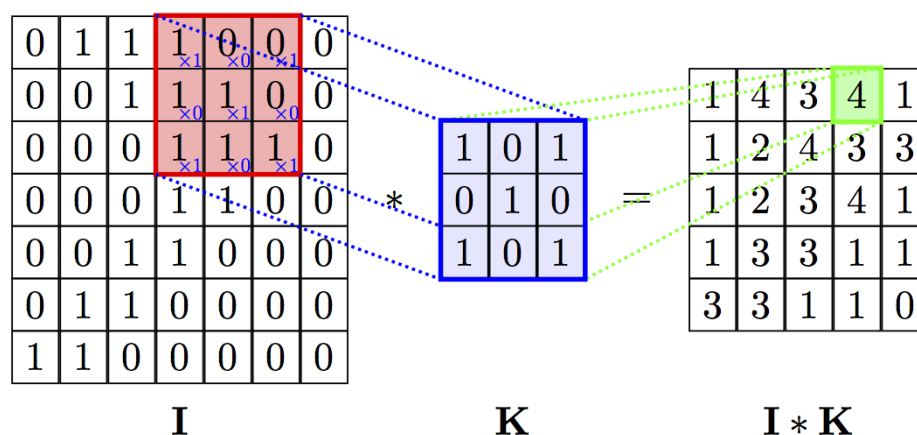
$$Gy = \begin{bmatrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ +1 & +1 & +1 \end{bmatrix}$$

Figura 1 – Uma borda será detectada entre o quarto e quinto pixel.



Fonte: Wikipédia

Figura 2 – Processo de convolução sendo realizado em um dado pixel.



Fonte: PetarV- (Github)

3.3 ROBERTS

$$G_x = \begin{bmatrix} +1 & 0 \\ 0 & -1 \end{bmatrix}$$

$$G_y = \begin{bmatrix} 0 & +1 \\ -1 & 0 \end{bmatrix}$$

3.4 LAPLACIAN OF GAUSSIAN

$$G = \begin{bmatrix} 0 & 0 & +1 & 0 & 0 \\ 0 & +1 & +2 & +1 & 0 \\ +1 & 0 & -16 & +1 & +1 \\ 0 & +1 & +2 & +1 & 0 \\ 0 & 0 & +1 & 0 & 0 \end{bmatrix}$$

3.5 SOBRE OS OPERADORES

A principal diferença entre os operadores são os valores dos pesos de cada operador, que

resultará em diferentes magnitudes de variação na escala de cinza. Eles majoram a sensibilidade dos operadores.

Esses operadores não possuem formas canônicas, mas sim diferentes versões deles. Podemos incluir neles pequenas modificações para alterarmos seus resultados. Em geral, é possível encontrar versões desses operadores com algumas constantes multiplicando a matriz para tornar a sensibilidade do operador sutilmente mais forte ou mais fraca.

Alguns destes operadores possuem mais de um kernel. O uso de múltiplos kernels é útil para convolucionar a imagem com base em diferentes sentidos (horizontal, vertical e até mesmo diagonal).

O resultado final destes operadores também se diferenciam. Podemos verificar essas diferenças na Figura 3.

A seguir, construímos uma matriz de similaridade (Figura 4) comparando par a par



Figura 3 – Original, Sobel, Prewitt, Roberts, Laplacian e Canny

todos os resultados obtidos entre os operadores. Essa matriz de similaridade foi baseada em uma versão simplificada da *Pratt's figure of merit* (PFOM), e utilizada em nossa análise quantitativa dos resultados.

4 CONSIDERAÇÕES FINAIS

Fica evidente que diferentes operadores diferenciais possuem diferentes vantagens e desvantagens. Isso faz com que cada um seja mais desejável dentro de uma aplicação específica. Os operadores trabalham utilizando o mesmo algoritmo de convolução, porém se diferenciam nos pesos em seus kernels, identificando diferentes magnitudes de bordas.

Alguns operadores se saem melhor com imagens livre de ruídos, outros se saem melhor em imagens mais escuras e assim sucessivamente. O critério a determinar qual operador é o mais indicado dependerá da situação. Mesmo assim, podemos compará-los tanto subjetivamente quanto objetivamente, através de métricas.

De maneira geral, podemos dizer que todos os operadores possuem resultados similares, apenas se diferenciando em pequenos detalhes, algumas vezes bem sutis. Ainda, todos trazem resultados satisfatórios, chegando perto

do algoritmo de Canny que é o estado da arte na detecção automática de bordas em imagens.

Uma comparação quantitativa se mostrou infrutífera, visto que os resultados numéricos variam muito conforme as diferentes imagens utilizadas. Mesmo assim, pudemos reconhecer alguns padrões. O operador de Sobel e o operador de Prewitt possuem alta similaridade em quase todos os testes. Depois, o operador de Roberts é o que mais se aproxima de Sobel e Prewitt, mas já com uma significativa diferença. O operador de Laplacian of Gaussian já muito se difere dos demais operadores.

O operador de Canny, que é o estado da arte, serviu como gabarito para um resultado ideal. Em geral todos os operadores diferenciais não conseguiam atingir nem 50% de similaridade com Canny. Isso se dá porque o algoritmo de Canny traz um resultado mais discreto e tende a descartar melhor ruídos ao invés de tratá-los como bordas.

Uma comparação qualitativa pareceu ser mais adequada para se analisar os resultados. Através dela pudemos reparar como é útil a etapa de borrar as imagens (aqui neste trabalho utilizamos o *Gaussian Blur*) para eliminarmos ruídos das imagens. Alguns desses operadores podem ser muito sensíveis a eventuais ruídos,

Figura 4 – Matriz de similaridade.

	Sobel	Prewitt	Roberts	Laplacian	Canny
Sobel	100.00%	99.86%	88.56%	53.64%	25.39%
Prewitt		100.00%	88.56%	53.66%	25.38%
Roberts			100.00%	54.90%	34.90%
Laplacian				100.00%	46.77%
Canny					100.00%

sendo assim muito importante borrar a imagem para obter um melhor resultado final.

4.1 FUTUROS TRABALHOS

Alguns pontos podem ser melhor explorados em trabalhos futuros. Não foi estudado neste artigo quais são os melhores métodos de pré-processamento das imagens antes de utilizarmos os operadores. A princípio, utilizamos apenas um operador de borra gaussiano. Não somente existem outros operadores de borra como também existem outros métodos e filtros que podem ser aplicados nas imagens antes de serem utilizados os operadores diferenciais para a detecção de imagens.

Também não foi tratado a questão das cores neste artigo. Aqui, apenas transformamos a imagem em uma escala de cinza antes de aplicarmos os operadores diferenciais. Jogamos fora informações que podem ser úteis mesmo para a detecção de bordas, com outros possíveis métodos diferentes do uso dos operadores diferenciais.

E por último, não nos aprofundamos nos diferentes métodos de análise quantitativa dos resultados. Fizemos uso apenas de uma versão simplificada do PFOM. Poderia ser feito uma análise quantitativa utilizando outros métodos e inclusive poderia ser feito uma comparação entre os resultados obtidos dos diferentes métodos possíveis.

4.2 REFERÊNCIAS BIBLIOGRÁFICAS

Existem diferentes trabalhos com abordagens similares, e, de maneira geral, eles obtêm resultados semelhantes ao comparar objetivamente os operadores (inclusive semelhantes aos resultados obtidos neste trabalho). É satisfatório o resultado deste trabalho uma vez que ele se mantém consistente com os demais trabalhos já existentes nesta área. Estes trabalhos incluem:

- On edge detection: (TORRE; POGGIO, 1986)
- Edge detection techniques - an overview: (ZIOU; TABBONE, 2000)
- Study and comparison of different edge detectors for image segmentation: (ACHARJYA RITABAN DAS, 2012)
- Differential operator based edge and line detection: (BEVINGTON; MERSE-REAU, 1987)
- A study on edge marking scheme of various standard edge detectors: (PANDE; BHADOURIA; GHOSHAL, 2012)

REFERÊNCIAS BIBLIOGRÁFICAS

ACHARJYA RITABAN DAS, D. G. D. P. P. Study and comparison of different

edge detectors for image segmentation.

Global Journal of Computer Science and Technology, 2012. ISSN 0975-4172.

Disponível em: <<https://computerresearch.org/index.php/computer/article/view/306>>.

BEVINGTON, J.; MERSEREAU, R.

Differential operator based edge and line detection. In: . [S.l.: s.n.], 1987. p. 249 – 252.

PANDE, S.; BHADOURIA, V. S.; GHOSHAL,

D. A study on edge marking scheme of various standard edge detectors. In: . [S.l.: s.n.], 2012.

TORRE, V.; POGGIO, T. On edge detection. **Pattern Analysis and Machine Intelligence, IEEE Transactions on**, PAMI-8, p. 147 – 163, 04 1986.

ZIOU, D.; TABBONE, S. Edge detection techniques - an overview. v. 8, 06 2000.